

Construction Of Deterministic Algorithms

Prabhakar Raghavan

Derandomisierung randomisierter Algorithmen

Sebastian Berndt

Arbeitsgruppe Diskrete Optimierung
Institut für Informatik
Christian-Albrechts-Universität zu Kiel

Juni 2011

Inhalt

1 KO 1 & KO 2

Inhalt

- 1 KO 1 & KO 2
- 2 Runden

Inhalt

- 1 KO 1 & KO 2
- 2 Runden
- 3 k-Matchings in Hypergraphen

Schnelle Wiederholung

\mathcal{NP} -vollständige Probleme sind schwer zu lösen.

- ⇒ Approximative Lösungen
- ⇒ Randomisierte Algorithmen

Lineare & Ganzzahlige Programme

Definition (Lineares / Ganzzahliges Programm)

Seien $A \in \mathbb{Q}^{m \times n}$, $c \in \mathbb{Q}^n$ und $b \in \mathbb{Q}^m$. Dann heißt

$$\max c^\top x$$

$$Ax \leq b$$

$$x \geq 0$$

$$(x \in \mathbb{N})$$

lineares (ganzzahliges) Programm.

Konvention: x_i sind ganzzahlige Lösungen, x_i^* sind fraktionale Lösungen.

$$\text{OPT} = c^\top x, \text{OPT}^* = c^\top x^*$$

Wichtige Theoreme

Theorem (Karp 1972)

Ganzzahlige Lineare Programme sind \mathcal{NP} -vollständig.

Wichtige Theoreme

Theorem (Karp 1972)

Ganzzahlige Lineare Programme sind \mathcal{NP} -vollständig.

Theorem (Khachiyan 1979)

Lineare Programme sind in \mathcal{P}

$LP \mapsto ILP$

Ab jetzt $x_i \in \{0, 1\}$ und $x_i^* \in [0, 1]$

$LP \mapsto ILP$

Ab jetzt $x_i \in \{0, 1\}$ und $x_i^* \in [0, 1]$

- Kaufmännisches Runden

$$x_i = \begin{cases} 1 & x_i^* \geq 0.5 \\ 0 & x_i^* < 0.5 \end{cases}$$

$LP \mapsto ILP$

Ab jetzt $x_i \in \{0, 1\}$ und $x_i^* \in [0, 1]$

- Kaufmännisches Runden

$$x_i = \begin{cases} 1 & x_i^* \geq 0.5 \\ 0 & x_i^* < 0.5 \end{cases}$$

- Randomisiertes Runden

$$\Pr[x_i = 1] = x_i^*$$

Derandomisierung

“Anyone who considers arithmetical methods of producing random digits is, of course, in a state of sin.”
(John von Neumann)


Derandomisierung

“Anyone who considers arithmetical methods of producing random digits is, of course, in a state of sin.”
(John von Neumann)

Lösung: Derandomisierung!


Entscheidungsbaum

Idee: Stelle Entscheidungen beim Runden als Baum dar!



Entscheidungsbaum

Idee: Stelle Entscheidungen beim Runden als Baum dar!



Notationen

- Entscheidungsbaum T
- Linker/Rechter Entscheidungsbaum T_L, T_R
- Teilbaum T^j , wenn x_1, \dots, x_j schon bestimmt

Notationen

- Entscheidungsbaum T
- Linker/Rechter Entscheidungsbaum T_L, T_R
- Teilbaum T^j , wenn x_1, \dots, x_j schon bestimmt
- Wahrscheinlichkeit für schlechtes Ereignis im Baum T^j , wenn die restlichen x_i per RR bestimmt werden: $\text{bad}(T^j)$
- $\text{bad}(T^j) \geq \min\{\text{bad}(T_L^j), \text{bad}(T_R^j)\}$

Algorithmische Idee

Gilt $1 > \text{bad}(T)$, so wähle also entweder T_L^j oder T_R^j !

Algorithmische Idee

Gilt $1 > \text{bad}(T)$, so wähle also entweder T_L^j oder T_R^j !

Erhalte Folge T_1, \dots, T_n mit

$$1 > \text{bad}(T) \geq \text{bad}(T_1) \geq \dots \geq \text{bad}(T_n)$$

Algorithmische Idee

Gilt $1 > \text{bad}(T)$, so wähle also entweder T_L^j oder T_R^j !

Erhalte Folge T_1, \dots, T_n mit

$$1 > \text{bad}(T) \geq \text{bad}(T_1) \geq \dots \geq \text{bad}(T_n)$$

T_n ist Blatt, also $\text{bad}(T_n) \in \{0, 1\}$. Somit $\text{bad}(T_n) = 0$!

Algorithmische Idee

Gilt $1 > \text{bad}(T)$, so wähle also entweder T_L^j oder T_R^j !

Erhalte Folge T_1, \dots, T_n mit

$$1 > \text{bad}(T) \geq \text{bad}(T_1) \geq \dots \geq \text{bad}(T_n)$$

T_n ist Blatt, also $\text{bad}(T_n) \in \{0, 1\}$. Somit $\text{bad}(T_n) = 0$!

Problem: T hat 2^n Blätter

Pessimistischer Schätzer

Definition (Pessimistischer Schätzer)

Für einen Entscheidungsbaum T und alle seine Teilbäume T^j heißt U pessimistischer Schätzer (Pessimistic Estimator), wenn:

- ① $1 > U(T)$
- ② $U(T^j) \geq \text{bad}(T^j)$
- ③ $U(T^j) \geq \min\{U(T^j_L), U(T^j_R)\}$
- ④ $U(T^j)$ ist polynomiell berechenbar

Pessimistischer Schätzer

Definition (Pessimistischer Schätzer)

Für einen Entscheidungsbaum T und alle seine Teilbäume T^j heißt U pessimistischer Schätzer (Pessimistic Estimator), wenn:

- 1 $1 > U(T)$
- 2 $U(T^j) \geq \text{bad}(T^j)$
- 3 $U(T^j) \geq \min\{U(T_L^j), U(T_R^j)\}$
- 4 $U(T^j)$ ist polynomiell berechenbar

Theorem (Hauptsatz)

Erhält man zu einem Problem Π via RR einen randomisierten Algorithmus mit Güte A und gibt es einen pessimistischen Schätzer für Π , so gibt es für Π einen deterministischen, polynomiellen Algorithmus mit Güte A .

Allgemeines Vorgehen

- 1 Löse LP
- 2 Zeige, dass es mit Randomisiertem Runden eine Lösung mit Güte A gibt
- 3 Bestimme einen pessimistischen Schätzer (durch Umbau des obigen Beweises)
- 4 Erhalte deterministischen Algorithmus mit Güte A

Problemstellung


Gegeben: Hypergraph H mit r Kanten und n Knoten

Gesucht: maximale Anzahl an Kanten, so dass jeder Knoten mit maximal k Kanten inzidiert.

Problemstellung

Gegeben: Hypergraph H mit r Kanten und n Knoten

Gesucht: maximale Anzahl an Kanten, so dass jeder Knoten mit maximal k Kanten inzidiert.




$$k = 2$$

Problemstellung

Gegeben: Hypergraph H mit r Kanten und n Knoten

Gesucht: maximale Anzahl an Kanten, so dass jeder Knoten mit maximal k Kanten inzidiert.



$k = 2$

Formulierung als IP

- $A \in \{0, 1\}^{n \times r}$ Inzidenzmatrix ($a_{ij} = 1 \Leftrightarrow v_i \in e_j$)
- $b = \vec{k}$
- $c = \vec{1}$
- x_j für Kante e_j

Formulierung als IP

- $A \in \{0, 1\}^{n \times r}$ Inzidenzmatrix ($a_{ij} = 1 \Leftrightarrow v_i \in e_j$)
- $b = \vec{k}$
- $c = \vec{1}$
- x_j für Kante e_j

IP für k -Matching

$$\begin{array}{ll} \max c^T x & \\ s.t. \sum_{j=1}^r a_{ij} x_j \leq k & \forall i \in \{1, \dots, n\} \\ x_j \in \{0, 1\} & \forall j \in \{1, \dots, r\} \end{array}$$

Randomisiertes Runden

- $\Rightarrow \mathbb{E}[\sum_{j=1}^r x_j] = \sum_{i=1}^r x_i^* = \text{OPT}^* \geq \text{OPT}$
- $\Rightarrow \mathbb{E}[\sum_{j=1}^r a_{ij} x_j] = \sum_{j=1}^r a_{ij} x_j^* \leq k$

Randomisiertes Runden

- $\Rightarrow \mathbb{E}[\sum_{j=1}^r x_j] = \sum_{i=1}^r x_i^* = \text{OPT}^* \geq \text{OPT}$
- $\Rightarrow \mathbb{E}[\sum_{j=1}^r a_{ij} x_j] = \sum_{j=1}^r a_{ij} x_j^* \leq k$

Problem: $\Pr[\sum_{j=1}^r a_{ij} x_j > k]$ ist sehr hoch!

Einschub

Lemma (Lemma 1)

X_i binäre Zufallsvariablen, $a_i \in [0, 1]$, $\delta > 0$, $\gamma \in (0, 1]$ und $X = \sum_i a_i X_i$.
Dann gilt:

$$\Pr[X > (1 + \delta)\mathbb{E}[X]] < \left(\frac{\exp(\delta)}{(1 + \delta)^{(1+\delta)}}\right)^{\mathbb{E}[X]} =: B(\mathbb{E}[X], \delta)$$

$$\Pr[X < (1 - \gamma)\mathbb{E}[X]] < B(\mathbb{E}[X], \gamma)$$

Einschub

Lemma (Lemma 1)

X_i binäre Zufallsvariablen, $a_i \in [0, 1]$, $\delta > 0$, $\gamma \in (0, 1]$ und $X = \sum_i a_i X_i$.
Dann gilt:

$$\Pr[X > (1 + \delta)\mathbb{E}[X]] < \left(\frac{\exp(\delta)}{(1 + \delta)^{(1+\delta)}}\right)^{\mathbb{E}[X]} =: B(\mathbb{E}[X], \delta)$$

$$\Pr[X < (1 - \gamma)\mathbb{E}[X]] < B(\mathbb{E}[X], \gamma)$$

Proof.

Markov-Ungleichung, $e^x \geq x + 1$, Bernoulli-Ungleichung



Einschub

Lemma (Lemma 1)

X_i binäre Zufallsvariablen, $a_i \in [0, 1]$, $\delta > 0, \gamma \in (0, 1]$ und $X = \sum_i a_i X_i$.
Dann gilt:

$$\Pr[X > (1 + \delta)\mathbb{E}[X]] < \left(\frac{\exp(\delta)}{(1 + \delta)^{(1+\delta)}}\right)^{\mathbb{E}[X]} =: B(\mathbb{E}[X], \delta)$$

$$\Pr[X < (1 - \gamma)\mathbb{E}[X]] < B(\mathbb{E}[X], \gamma)$$

Proof.

Markov-Ungleichung, $e^x \geq x + 1$, Bernoulli-Ungleichung □

Zur Abkürzung: $D(\mathbb{E}[X], x)$ mit $B(\mathbb{E}[X], D(\mathbb{E}[X], x)) = x$.

Lösung

Skalierung

Skaliere $\Pr[x_i = 1]$ mit $\alpha \in (0, 1)$, so dass $B(\alpha k, \frac{1-\alpha}{\alpha}) \leq \frac{1}{n+1}$

Erhalte dann x_j^S mit $\Pr[x_j^S = 1] = \alpha x_j^*$.

Lösung

Skalierung

Skaliere $\Pr[x_i = 1]$ mit $\alpha \in (0, 1)$, so dass $B(\alpha k, \frac{1-\alpha}{\alpha}) \leq \frac{1}{n+1}$

Erhalte dann x_j^S mit $\Pr[x_j^S = 1] = \alpha x_j^*$.

Lemma (Lemma 2)

Falls $k > \ln(n)$, so ist α konstant.

Falls $k \leq \ln(n)$, so ist α abhängig von n .

Lösung

Skalierung

Skaliere $\Pr[x_i = 1]$ mit $\alpha \in (0, 1)$, so dass $B(\alpha k, \frac{1-\alpha}{\alpha}) \leq \frac{1}{n+1}$

Erhalte dann x_j^S mit $\Pr[x_j^S = 1] = \alpha x_j^*$.

Lemma (Lemma 2)

Falls $k > \ln(n)$, so ist α konstant.

Falls $k \leq \ln(n)$, so ist α abhängig von n .

Theorem

Es gibt ein k -Matching mit Kardinalität K mit

$$K \geq \alpha \text{OPT}^* \cdot (1 - D(\alpha \text{OPT}^*, 1/(n+1)))$$

Warnung

Ab hier:

Ein konkreter pessimistischer Schätzer für k -Matchings.

Warnung

Here be dragons! ($e^x, \ln(x), \dots$)

Einschub 2

Lemma (Lemma 3)

Es gilt mit $t = \ln(1 + D(\alpha k, \frac{1-\alpha}{\alpha}))$, $t' = \ln(1 + D(\alpha \text{OPT}^*, 1/(n+1)))$ und $\mu = \alpha \text{OPT}^*$:

$$\Pr\left[\sum_{j=1}^r a_{ij} x_j^S > k\right] \leq \exp(-tk) \prod_{j=1}^r [x_j^* \exp(t a_{ij}) + 1 - x_j^*]$$

$$\Pr\left[\sum_{j=1}^r x_j^S < \mu(1 - D(\mu, 1/(n+1)))\right] \leq$$

$$\exp(t' \mu(1 - D(\mu, 1/(n+1)))) \prod_{j=1}^r [x_j^* \exp(-t') + 1 - x_j^*]$$

Proof.

Zwischenergebnis Lemma 1



Der gesuchte Schätzer

Theorem (Pessimistischer Schätzer für k -Matching)

Das folgende U ist ein pessimistischer Schätzer für k -Matching mit $\mu = \alpha \text{OPT}^*$:

$$U(T) = \sum_{i=1}^n e^{-tk} \prod_{j=1}^r [x_j^* e^{a_{ij}t} + 1 - x_j^*] \\ + e^{t'\mu(1-D(\mu, 1/n+1))} \prod_{j=1}^r [x_j^* e^{-t'} + 1 - x_j^*]$$

mit $t = \ln(1 + D(\alpha k, \frac{1-\alpha}{\alpha}))$, $t' = \ln(1 + D(\mu, 1/n + 1))$

Ziellinie

Theorem

Für einen Hypergraphen lässt sich deterministisch in polynomieller Zeit ein k -Matching der Kardinalität K mit

$$K \geq \alpha \text{OPT}^* \cdot (1 - D(\alpha \text{OPT}^*, 1/(n+1))) = \mu(1 - D(\mu, 1/(n+1)))$$

bestimmen.

Allgemeines Vorgehen

- 1 Löse LP
- 2 Zeige, dass es mit Randomisiertem Runden eine Lösung mit Güte A gibt
- 3 Bestimme einen pessimistischen Schätzer (durch Umbau des obigen Beweises)
- 4 Erhalte deterministischen Algorithmus mit Güte A

Danke!
Fragen?